Очистка и подготовка данных

Как из полевых замеров XRF и материалов портала chemicals.tj получены таблицы, на которых работают модели и карты стенда. Для каждого шага указано, что проверялось, что исправлено и каким скриптом это воспроизводится.

> Общие правила для обеих тем: исходные файлы не изменяются; каждое значение в итоговых таблицах ссылается на документ или замер, из которого оно получено; спорные случаи не удаляются, а помечаются флагом и остаются в данных; все шаги выполняются скриптами и повторяются заново от исходных материалов.

1. Тяжёлые металлы (XRF)

1.1. Исходные данные

- Полевые замеры портативным рентгенофлуоресцентным анализатором (XRF): 10 складов, 169 точек, 9 элементов (As, Co, Hg, Mo, Pb, Rb, Th, U, Zn).
- Контуры складов (полигоны) и координаты точек замеров в формате GeoJSON.
- Открытые данные для признаков модели: реки и каналы (OpenStreetMap), pH почвы (SoilGrids), рельеф, климат, население, землепользование, геология.

1.2. Загрузка и исправленные проблемы формата

Проблема	Как проявлялась	Решение
Кириллические имена файлов	на macOS разная нормализация Unicode (NFC/NFD) — файлы молча не находились	файлы переименованы в латиницу
Повторяющийся столбец `name` в GeoJSON	конфликт имён при переименовании полей	перед переименованием выбираются только нужные столбцы
Трёхмерные координаты (EPSG:4979, Z = 0)	несовпадение с системой координат базы (EPSG:4326)	координаты приводятся к 2D перед записью
Контур склада «Кушониён» совпадал с контуром «Шахринав»	найдено при сверке геометрий на раннем этапе	контур заменён; буферы 50 и 100 м строятся из контура автоматически (представление в базе), а не хранятся отдельно, чтобы геометрии не расходились

Скрипт загрузки: `db/import_data.py`.

1.3. Контроль геометрии

- Все 10 контуров проверены на корректность и самопересечения, все 45 пар контуров — на перекрытия и вложенность буферов (`db/qc_geometry.py`). Замечаний нет.
- Площадь складов — от 0,05 до 1,07 га.
- Внутри контура лежат 49 точек из 169; у точек снаружи медианное расстояние до контура — 49 м, 11 точек дальше 100 м, самая дальняя — 126 м. Точки вне контура не удаляются: расстояние до контура (со знаком «внутри / снаружи») и зона (внутри, до 50 м, до 100 м, дальше) используются как признаки модели.

1.4. Значения

- Значения ниже предела обнаружения не отбрасываются: они заменяются половиной предела (LOD/2) и помечаются `below_lod`.
- Для модели берётся логарифм концентрации и вычитается медиана логарифма по своему складу. Так модель учится положению очага внутри склада, а не различиям между складами; при 10 складах абсолютный прогноз по стране не получается.
- У портативного XRF предел обнаружения мышьяка и ртути близок к нормативам, поэтому превышения по As и Hg рассматриваются как сигнал для лабораторной проверки. Для свинца и цинка XRF надёжен.

1.5. Признаки из открытых данных

Собраны и хранятся в базе все кандидаты: расстояние до воды, pH, уклон, высота, население, землепользование, геология, накопление стока, климат. Каждый проверен по одной схеме — обучение на 9 складах, проверка на десятом (LOWO). В модель вошли только признаки, которые не ухудшают качество в сочетании: расстояние до воды по точке (OpenStreetMap) и pH почвы по складу (SoilGrids). У одного склада нет значения pH — подставляется среднее по выборке. Подробности и результаты проверок — на странице «Методика: металлы».

Скрипты: `db/fetch_point_covariates.py`, `db/fetch_landcover_population.py`, `db/diagnose_features.py`, `db/scan_all_substances.py`.

1.6. Производные таблицы

- Приоритет складов — `db/rank_sites_priority.py`: композитный индекс по Pb, As, Hg, Zn (превышение над медианой всей съёмки в логарифмах).
- Зоны загрязнения внутри склада — `db/build_risk_zones.py`: по реальным точкам, без интерполяции.
- Модель Pb — `db/run_model_and_store.py`.

- Выгрузка для блокнотов без базы данных — `db/export_geopackage.py` → `tajikistan_soil_ml_export.gpkg`.

2. Участки СОЗ-пестицидов (chemicals.tj)

2.1. Исходные данные

Структурированных таблиц у заказчика нет. Все сведения взяты из открытой части портала chemicals.tj:

- карта: 192 участка типа «СОЗ» с координатами и статусом («загрязнённый» / «очищенный»);
- анкета обследования по каждому участку — около 50 полей: площадь, запах, яма, доступ, вода, грунтовые воды, жители в кольцах 50/100/500 м и др.;
- текстовое описание участка;
- вложения: фотографии, лабораторные протоколы, журналы и реестры отбора проб, отчёты.

Скрипт выгрузки: `db/fetch_chemicals_tj.py --download-docs`.

2.2. Документы

- Одни и те же документы прикреплены к разным участкам. Копии сведены по контрольной сумме файла и по совпадению извлечённого текста: из 373 вложений-документов осталось 245 разных.
- Документы классифицированы: лабораторный протокол, журнал или реестр отбора проб, отчёт, прочее. Определено, есть ли в PDF текстовый слой.

2.3. Извлечение анализов

Тип документа	Как извлекается	Проверка
Текстовые PDF (протокол АФИ №8, отчёт ИЛИМ №42, таблица Института химии 2012 г., журналы)	разбор таблиц по шаблонам; у журналов несколько разных шаблонов, в том числе блоки с несколькими участками	каждое значение найдено дословно в тексте своего документа; 32 случая, где цифры перекрыты текстом соседней колонки, помечены
Сканы без текстового слоя (протокол АФИ №126 — 286 проб, письмо Института химии 2017 г.)	перенесены вручную в таблицы `manual/*.csv` с примечаниями об опечатках в оригинале	журналы 2019 г. совпали с протоколом №126 по 229 из 233 наборов «участок × вещество»

Скрипт: `db/extract_pop_tables.py` → `extracted/measurements_long.csv`.

2.4. Приведение к единому виду

- Единица — мг/кг. Названия веществ приведены к единому словарю: ДДТ, ДДД, ДДЕ, изомеры ГХЦГ (α, β, γ, δ), альдрин, дильдрин, гептахлор и др.
- «Не обнаружено» хранится как отдельный признак; в суммах групп считается нулём.
- Колонки журналов без названия вещества сохраняются в отдельных полях и в показатель загрязнения не входят.
- Показатель загрязнения участка — максимум по пробам из двух сумм: ДДТ+ДДД+ДДЕ и суммы изомеров ГХЦГ.

> Исправленная ошибка сборки: если одно из веществ группы в пробе было «не обнаружено», сумма группы становилась пустой, и у части участков пропадало значение загрязнения. После исправления число участков с анализами выросло со 159 до 169; модель, индекс риска, план отбора и аудит пересчитаны.

2.5. Дубли между источниками

Одна и та же проба часто есть и в журнале отбора, и в лабораторном протоколе. Каждому значению присвоен ранг источника:

Ранг	Источник	В сводной выборке
1	лабораторный протокол	да
2	журнал или реестр, если этой пробы нет в протоколах	да
0	журнал, дублирующий протокол	нет, остаётся в данных с пометкой

При расхождении значений в сводную выборку идёт протокол. Реестры 2020 г. совпали с протоколом №8 по 47 из 48 участков. Итог: 586 проб и 2823 значения концентраций без дублей; всего извлечено 4572 значения.

2.6. Координаты проб

Лабораторные протоколы координат не содержат. Координаты перенесены из журналов и реестров того же участка, способ записан у каждой пробы:

- по совпадению значения ДДТ в журнале и протоколе (протокол №126);
- по порядку повторностей Т1/Т2/К3 в реестре (протокол №8);
- по номеру пробы (отчёт ИЛИМ 2016 г.);
- из самого журнала, если координаты указаны в нём.

Так получены координаты 462 проб; медианное расстояние от пробы до точки участка — около 30 м. Пробы без координат поставлены в точку участка с пометкой; участки, которых нет на карте, остаются без геометрии.

2.7. Связка кодов участков

В протоколе №126 12 участков записаны полевыми кодами tj77xx, которых нет на карте. 9 из них по названию села уверенно связаны с карточками карты (таблица `manual/protocol126_map_links.csv`), 3 остаются неоднозначными и вынесены в слой отдельными участками без координат. Код TJ-7580 на карте использован дважды для разных карточек — участки различаются по координатам.

2.8. Сведения из текста карточек

Из текстовых описаний по шаблонам извлечено около 2200 фактов: расстояния до жилья, воды, дорог, посевов, школы и колодца; число жителей, детей, семей и домов; количество пестицидов, площадь; упоминания детей, скота, посевов, питьевой воды, жалоб на здоровье, ремедиации. Для каждого факта сохранён фрагмент текста-основание, чтобы его можно было проверить.

2.9. Признаки из открытых данных

Для каждого участка по локальным растрам (без обращений в интернет) посчитаны: pH почвы (SoilGrids), высота и уклон (рельеф 150 м), население в радиусе ~500 м и 1 км (WorldPop 2020), накопление стока, среднегодовые температура и осадки (WorldClim 2.1). Скрипт: `db/pop_site_covariates.py`.

2.10. Аудит качества данных портала

По итогам подготовки собран перечень проблем самого портала с доказательствами и действием для исправления (`audit/data_quality_audit.csv`, скрипт `db/pop_data_audit.py`): 63 проблемы, из них 16 высокой важности.

Категория	Проблем	Примеры
Идентификация	19	повторяющийся код TJ-7580; коды из протокола, которых нет на карте; близкие дубликаты участков
Координаты	13	пробы дальше 2 км от точки участка; перепутанные заголовки широты и долготы; низкая точность
Анализы	10	расхождения журнала и протокола; колонки без названия вещества
Статус	9	шесть участков отмечены «очищенными», но анализы показывают загрязнение выше норматива
Документы	7	журналы прикреплены к чужим участкам; сканы без текстового слоя
Прочее	5	разные шаблоны журналов, пустые поля анкеты, служебный текст в описаниях

2.11. Результат

Слой `source_data/chemicals_tj/pop_layer/pop_layer.gpkg` и те же таблицы в CSV; описание полей — `data_dictionary.md`.

Слой	Содержание
`pop_sites`	участки: анкета, сводные показатели загрязнения, факты из текста, ссылки на документы
`pop_samples`	пробы сводной выборки, вещества в отдельных колонках, источник координат
`pop_measurements`	все извлечённые значения «проба × вещество», включая дубли (ранг 0)
`pop_text_facts`	факт из текста и фрагмент-основание
`pop_files`	все вложения участков со ссылками
`pop_sources`	источники лабораторных данных

3. Как воспроизвести

Металлы (нужна база PostgreSQL/PostGIS стенда):

```
python db/import_data.py
python db/qc_geometry.py
python db/fetch_point_covariates.py
```

```
python db/rank_sites_priority.py
python db/build_risk_zones.py
python db/run_model_and_store.py "причина пересчёта"
python db/export_geopackage.py
```

СОЗ (только файлы, база не нужна):

```
python db/fetch_chemicals_tj.py --download-docs
python db/extract_pop_tables.py
python db/build_pop_layer.py
python db/pop_site_covariates.py
python db/pop_screening_model.py          # можно прерывать и продолжать
python db/pop_screening_model.py final
python db/pop_child_risk_index.py
python db/pop_data_audit.py
python db/pop_sampling_plan.py
python db/pop_metals_link.py
```

Первый шаг обращается к порталу chemicals.tj; остальные работают без интернета.