Методика пилота: скрининг участков СОЗ и риск для детей (Таджикистан)

Назначение пилота

Пилот показывает, что по уже собранным на chemicals.tj сведениям можно ранжировать участки устаревших пестицидов (СОЗ) по риску для детей и заранее выделять участки, где вероятно сильное загрязнение. Это даёт основу для очерёдности обследования и ремедиации без новых полевых работ.

Вопрос пилота: **где дети подвергаются наибольшему риску от бывших складов и захоронений пестицидов и что из этого можно оценить для мест без лабораторных анализов.** Логика оценки риска повторяет детский индекс климатических и экологических рисков UNICEF (CCRI-DRM): риск = опасность × воздействие на детей × уязвимость (пути воздействия).

Пилот состоит из четырёх результатов:

- сводный слой СОЗ: все участки карты chemicals.tj, пробы и показатели из прикреплённых документов с привязкой к координатам;
- модель скрининга: оценка вероятности сильного загрязнения участка до лабораторного анализа;
- индекс риска для детей по каждому участку;
- демо-стенд с картой, карточками участков и оценкой нового участка, а также план следующей кампании отбора проб.

Работа с тяжёлыми металлами (XRF на 10 складах) продолжается параллельно; общие площадки двух тем рассмотрены в отдельном разделе.

Данные

Слой СОЗ собран целиком из открытых данных карты chemicals.tj: 192 участка типа «СОЗ», 586 проб, 2823 значения концентраций в сводной выборке (без дублей). Анализы на ДДТ или ГХЦГ есть по 169 участкам карты — лабораторные протоколы и значения из журналов отбора вместе.

Источники. Карта отдаёт по каждому участку анкету обследования (около 50 полей: площадь, запах, доступ, вода, население в кольцах 50/100/500 м), текстовое описание и вложения. Из 373 вложений-документов после сведения копий по тексту осталось 245 разных: лабораторные протоколы, журналы и реестры отбора проб, отчёты.

Источник анализов	Отбор	Проб	Вещества	Как получено
ФГБНУ «Агрофизический НИИ», протокол №126 от 20.09.2019	2019	286	ДДТ, ДДД, ДДЕ, γ-ГХЦГ	скан, перенесён вручную и сверен с журналами
ФГБНУ «Агрофизический НИИ», протокол №8 от 12.02.2021	2020	157	ДДТ, ДДЕ, α-, β-, γ-ГХЦГ	текстовый PDF
ОсОО «НПО ИЛИМ» (Бишкек), отчёт №42 от 01.03.2017, EPA 8081	2016	31	17 хлорорганических пестицидов	текстовый PDF
Институт химии им. В.И. Никитина, таблица от 27.07.2012	2012	16	10 пестицидов	текстовый PDF
Институт химии им. В.И. Никитина, письмо от 27.10.2017	2017	7	суммы обнаруженных веществ	скан, перенесён вручную
Журналы и реестры отбора проб (без лабораторного дубля)	2014–2020	89	ДДТ, ДДД, ДДЕ; часть без названия вещества	текстовый PDF

Извлечение и проверка. Таблицы текстовых PDF разобраны автоматически; каждое значение найдено дословно в тексте своего документа, кроме 32 помеченных случаев, где цифры перекрыты текстом соседней колонки. Реестры 2020 г. совпали с протоколом №8 по 47 из 48 участков, журналы 2019 г. с протоколом №126 — по 229 из 233 наборов «участок × вещество». При расхождении в сводную выборку идёт лабораторный протокол; журнал, дублирующий протокол, остаётся в данных с пометкой о дубле.

Координаты проб. Лабораторные протоколы координат не содержат. У 462 проб координаты взяты из журналов и реестров того же участка: по совпадению значения ДДТ, по порядку повторностей Т1/Т2/К3 или по номеру пробы; способ записан у каждой пробы. Медианное расстояние от пробы до точки участка — около 30 м. Остальные пробы поставлены в точку участка или, если участка нет на карте, остались без геометрии.

Связка кодов. В протоколе №126 12 участков записаны полевыми кодами tj77xx, которых нет на карте. 9 из них по названию села уверенно связаны с карточками карты, 3 остаются неоднозначными и вынесены в слой отдельными участками без координат.

Показатель загрязнения участка — максимум по пробам из двух сумм: ДДТ+ДДД+ДДЕ и изомеров ГХЦГ, мг/кг. «Не обнаружено» входит в сумму как 0. Опорный уровень — норматив ДДТ 0,1 мг/кг. Из 169 обследованных участков норматив превышен на 162, в 100 раз (10 мг/кг) — на 106, в 1000 раз (100 мг/кг) — на 52. Максимум — 3601 мг/кг (TJ-7485).

Модель скрининга

Модель отличает сильно загрязнённые участки от остальных по сведениям, доступным до анализа: AUC 0,70 при пространственной проверке (перестановочный тест p = 0,003). Она задаёт очерёдность обследования, но не заменяет лабораторию.

Цель. Участок «сильно загрязнён», если хотя бы в одной пробе ДДТ+ДДД+ДДЕ или сумма изомеров ГХЦГ ≥ 100 мг/кг (в 1000 раз выше норматива). Обучающая выборка — 169 обследованных участков, из них 52 сильно загрязнены.

Признаки (без сведений из анализов):

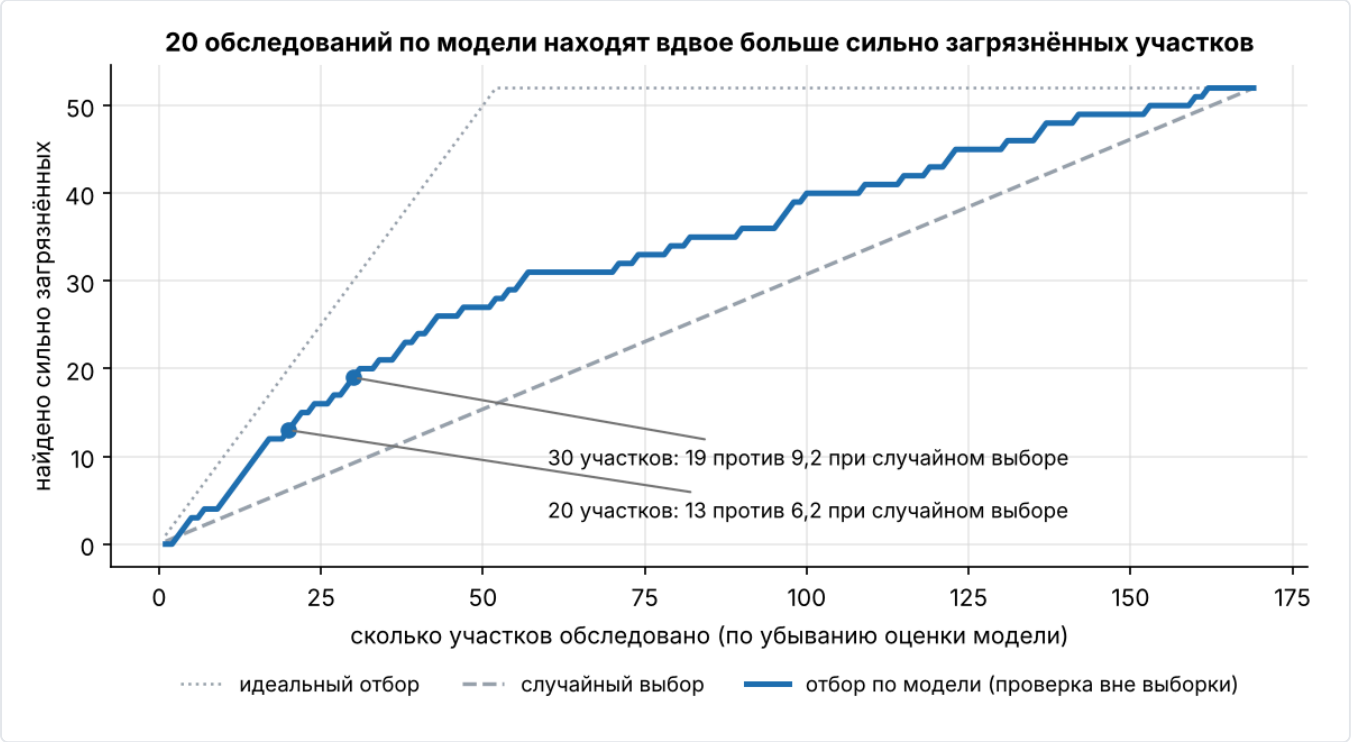
- анкета обследования chemicals.tj: площадь, запах, яма, доступ, покрытие почвы, посевы, животные, вода, грунтовые воды, население;
- место: область, координаты;
- загрязнение пяти ближайших обследованных участков (только из обучающей части);
- открытые данные по локальным растрам: pH почвы (SoilGrids), высота и уклон (DEM 150 м), население в радиусе \~500 м (WorldPop 2020; для индекса риска — WorldPop R2025A), накопление стока, среднегодовые температура и осадки (WorldClim 2.1).

Алгоритм — логистическая регрессия с регуляризацией (scikit-learn), без внешних сервисов.

Проверка. Участки делятся на 10 кластеров по координатам; каждый кластер по очереди откладывается целиком, чтобы соседи проверяемого участка не попадали в обучение. 10 повторов с разной разбивкой. Значимость — перестановочный тест: метки перемешиваются, и весь прогон повторяется; в 304 повторах ни один не достиг итогового качества.

Набор признаков	AUC
Открытые данные (pH, рельеф, население, сток, климат)	0,72
Анкета + место + соседи + открытые данные (итоговая модель)	0,70
Анкета	0,67
Место + соседи	0,63
Анкета + текст карточки	0,60

Итоговый набор выбран до последнего пересчёта и не перевыбирался, чтобы не подгонять выбор под результат. Признаки из текста карточек качество снизили (переобучение при 169 участках) и в модель не входят.



Проверка вне выборки, 169 участков chemicals.tj, цель ≥100 мг/кг

Модель делит участки на три класса по ранговой оценке. В классе «высокий» сильно загрязнено 54 % обследованных участков, в «среднем» и «низком» — 18–19 %: модель надёжно выделяет верхнюю треть, а среднюю и нижнюю различает слабо.

Индекс риска для детей

Индекс показывает, где загрязнение опаснее всего именно для детей. Он построен по логике CCRI-DRM UNICEF (риск = опасность × воздействие × уязвимость), считается прозрачно, без обучения; все веса заданы в начале скрипта `db/pop_child_risk_index.py` и меняются без перепрограммирования.

Компонента	Как считается	Источник
Опасность H (0–1)	log10(burden / 0,1) / 4: норматив 0,1 мг/кг → 0, 1000 мг/кг → 1. Участок без анализов получает среднюю H обследованных участков того же класса скрининга	слой CO3, модель скрининга
Воздействие E (0–1)	0,6 × ранг числа детей в радиусе 1 км + 0,25 × ранг числа людей на участке и в 100 м + 0,15 × упоминание школы или детей в карточке	WorldPop R2025A, растр «до 18 лет» (100 м); анкета
Уязвимость V (0–1)	0,7 × доля путей воздействия из семи (питьевая вода, орошение, скот, посевы, лёгкий доступ, паводок или река ближе 300 м, грунтовые воды ближе 10 м) + 0,3 × бедность (1 − национальный процентиль индекса благосостояния RWI в радиусе 2 км)	анкета и текст карточки; Meta Relative Wealth Index
Риск	(H × E × V)^(1/3); классы: 50 % низкий, 30 % средний, 15 % высокий, 5 % очень высокий	

Число детей берётся напрямую из возрастного растра WorldPop R2025A (дети 0–17 лет, 2025 год, шаг 100 м); дети до 5 лет — сумма растров 0–1 и 1–4 года. Прежняя версия умножала общее население WorldPop 2020 на единую долю 0,40; новая оценка с ней согласуется (корреляция рангов риска 0,95, восемь из десяти верхних участков те же), но в среднем даёт в 1,5 раза больше детей у участка. Точность растров WorldPop на уровне джамоатов можно проверить только по данным переписи. Если файлов R2025A нет, скрипт возвращается к прежней схеме с региональными долями детей UNFPA (Согд 0,38, РРП 0,41, Хатлон 0,43).

Результаты по 192 участкам карты:

- в радиусе 1 км от участков живут около 244 тыс. детей, из них около 75 тыс. младше 5 лет; 112 тыс. — рядом с участками, где загрязнение выше норматива в 100 и более раз (≥10 мг/кг), 59 тыс. (из них 18 тыс. младше 5 лет) — рядом с сильно загрязнёнными (≥100 мг/кг);
- на 56 участках вода с участка или рядом используется для питья, 118 находятся в зоне затопления или ближе 300 м к реке, в 102 карточках упоминаются дети или школа;
- классы: очень высокий — 10 участков, высокий — 29, средний — 57, низкий — 96. Девять из десяти участков очень высокого класса находятся в Хатлонской области;
- 3 участка из 39 верхних классов не имеют анализов, их опасность оценена моделью скрининга; 5 других отмечены на карте как «очищенные», хотя анализы на сайте показывают загрязнение выше норматива.

Десять участков с наибольшим риском:

№	Код	Участок	burden, мг/кг	Детей в 1 км	Из них до 5 лет	Бедность (RWI, 0–1)	Путей воздействия из 7
1	TJ-7527	бывший склад, с. Чуибор, Кумсангир	2306	2519	788	0,41	6
2	TJ-7448	бывший склад, пос. Большевик-1 (отмечен «очищенным»)	1342	611	191	0,44	6
3	TJ-7522	бывший склад, с. Бешкент (Комсомол)	819	1169	366	0,26	7
4	TJ-8182	Сельхозхимия, Ортиков, Канибадам	103	1640	478	0,52	5
5	TJ-7634	склад совхоза Томин, с. Сулхобод	358	2359	737	0,12	5
6	TJ-7561	бывший склад, Сангоба (отмечен «очищенным»)	2238	1167	365	0,28	5
7	TJ-7528	бывший склад, Эмамадов, джамоат Вахдати Милли	305	1421	444	0,52	4
8	TJ-7420	склад в Лагмоне, Куляб	53	2273	711	0,23	7
9	TJ-7486	захоронение, с. Айни, Навбахор (отмечен «очищенным»)	695	543	170	0,24	6
10	TJ-7443	бывший склад, с. Намуна, джамоат Г. Гулмуродова	12	3981	1245	0,33	6

Индекс отвечает на вопрос «где вмешательство защитит больше детей», а модель скрининга — «где искать загрязнение». Участок с умеренным загрязнением рядом с крупным селом и питьевым источником может стоять в рейтинге выше сильно загрязнённого удалённого участка.

Применение

Демо-стенд работает локально, без доступа в интернет (Flask, Leaflet и подложка рельефа хранятся вместе со стендом). Разделы:

- «Карта: СОЗ» — все участки с раскраской по риску для детей, по загрязнению или по классу скрининга; обследованные участки — сплошные круги, оценённые моделью — пунктирные кольца; фильтры по области, статусу и классу; рейтинг участков и список кандидатов на обследование; карточка участка с пробами, путями воздействия и документами;
- «СОЗ: скрининг» — кривая отбора, кандидаты на обследование, метрики модели, ограничения, выгрузки;
- форма оценки нового участка: специалист вводит данные анкеты и координаты, стенд возвращает класс скрининга и индекс риска для детей за секунды. Так модель встраивается в работу инспектора: новый участок сразу получает очерёдность.

План следующей кампании отбора проб (`sampling_plan/`): 37 участков, около 190 проб, в четырёх группах.

Группа	Участков	Проб	Зачем
Первичная оценка	14	56	нет данных о ДДТ/ГХЦГ; выбраны по модели и числу детей рядом
Контроль очистки	9	36	участки «очищены», но анализы показывают загрязнение, или данных после очистки нет
Оконтуривание очага	8	80	сильно загрязнённые участки с детьми рядом: границы очага для ремедиации
Обновление данных	6	18	последние анализы 2012–2016 гг.

В первой группе модель ожидает около 4 сильно загрязнённых участков из 14. Рядом с участками плана живут около 45 тыс. детей. Для каждого участка в плане указаны известные проблемы данных из аудита, чтобы их устранили при выезде.

Результаты кампании проверят прогноз модели на новых участках и дадут данные для её переобучения.

Качество данных chemicals.tj

Аудит (`audit/data_quality_audit.csv`) нашёл 63 проблемы: 16 высокой важности, 36 средней, 9 низкой. Каждая запись содержит коды участков, доказательство и действие для исправления на сайте.

Категория	Проблем	Главное
Идентификация	19	код TJ-7580 у двух разных карточек; в протоколе №126 коды TJ-7722, TJ-7724, TJ-7729, которых нет на карте; близкие дубликаты участков
Координаты	13	у трёх участков пробы дальше 2 км от точки участка; перепутанные заголовки широты и долготы; низкая точность
Анализы	10	расхождения значений между журналом и протоколом; колонки без названия вещества
Статус	9	шесть участков отмечены «очищенными», но единственные анализы показывают загрязнение выше норматива (TJ-4958, TJ-7448, TJ-7486, TJ-7561, TJ-7582, TJ-7597)
Документы	7	журналы прикреплены к чужим участкам (TJ-7414, TJ-7606, TJ-7447); сканы без текстового слоя
Прочее	5	разные шаблоны журналов, пустые поля анкеты, служебный текст в описаниях

При сверке извлечённых значений со сканами протоколов совпало 229 из 233. Самое важное для заказчика — статусы «очищен»: если они неверны, люди вблизи этих участков считаются защищёнными, хотя загрязнение сохраняется. Эти участки включены в план кампании (группа «Контроль очистки»).

СОЗ и тяжёлые металлы

9 из 10 складов, где проект вел XRF-съёмку металлов, совпадают с участками СОЗ на chemicals.tj (ближе 150 м); не совпадает только Шахринав. Анализы на ДДТ/ГХЦГ есть на 6 из 9 общих площадок (`metals_link/`).

Уровень площадки. Приоритет по металлам и загрязнение пестицидами связаны слабо (ранговая корреляция 0,37 по 6 площадкам, незначима). Вахш и Дусти — в верху обоих рейтингов; Джамийский район высокий по металлам, но пестицидов почти нет (0,17 мг/кг).

Уровень точки. 12 проб СОЗ имеют точку XRF ближе 50 м. Статистически связь не подтверждается (с свинцом 0,29, с мышьяком, ртутью и цинком 0,14–0,21), но на трёх площадках очаги совпали:

- Дж. Балхи: самая загрязнённая проба СОЗ — рядом с точкой максимума свинца на площадке;
- Дусти: две самые загрязнённые пробы СОЗ — рядом со 2-й из 19 точкой по свинцу;
- Кушониён: самая загрязнённая проба СОЗ — рядом с точкой максимума свинца.

Это основание проверить гипотезу, что на складах пестициды и металлы концентрируются в одних местах. Если она подтвердится, дешёвая полевая XRF-съёмка сможет подсказывать, где брать дорогие лабораторные пробы на пестициды. Для проверки нужен совместный отбор (XRF и лаборатория в одних точках) в следующей кампании.

Ограничения и развитие

Ограничения пилота:

- 169 обследованных участков — мало для сложных моделей; модель надёжно выделяет верхнюю треть участков, средний и низкий классы различает слабо;
- анализы извлечены из журналов и протоколов разных лет и лабораторий; часть данных 2012–2016 гг. могла устареть;
- опасность участка оценивается по самой загрязнённой пробе; площадь и объём очага не учитываются;
- число детей — модельная оценка WorldPop, не перепись; школы и детсады учтены только по упоминаниям в карточках;
- для 23 участков без анализов опасность — прогноз, а не измерение.

Развитие при продолжении проекта:

1. Провести кампанию по плану отбора и сравнить результат с прогнозом — независимая проверка модели; затем переобучить её.
2. Ввести единую форму внесения анализов (таблица вместо PDF), единые коды участков и проб, координаты каждой пробы.
3. Добавить школы и детсады из OpenStreetMap, источники питьевой воды; сверить растр детей WorldPop с данными переписи по джамоатам.
4. Совместный отбор XRF + лаборатория для проверки связи металлов и пестицидов.
5. Расширить модель с участка на территорию: карта вероятного распространения загрязнения вокруг очагов с учётом стока и паводков.

Состав результатов

Все файлы — в проекте стенда, папка `source_data/chemicals_tj/pop_layer/`; скрипты — в `db/`. Всё воспроизводится заново от выгрузки сайта до индекса риска.

Результат	Файлы	Скрипт
Выгрузка карты и документов	`sites.csv`, `files.csv`, `docs/`	`fetch_chemicals_tj.py`
Извлечение анализов из PDF	`extracted/measurements_long.csv`	`extract_pop_tables.py`
Слой СОЗ (участки, пробы, измерения, факты из текста)	`pop_layer.gpkg`, CSV, `data_dictionary.md`	`build_pop_layer.py`
Признаки из открытых данных	`site_covariates_pop.csv`	`pop_site_covariates.py`
Модель скрининга	`model/`: кривая отбора, прогнозы, важность признаков, README	`pop_screening_model.py`
Индекс риска для детей	`child_risk/child_risk_index.csv`, `.gpkg`	`pop_child_risk_index.py`
Аудит данных	`audit/data_quality_audit.csv`, `audit_summary.csv`	`pop_data_audit.py`
План отбора проб	`sampling_plan/sampling_plan.csv`, `.gpkg`	`pop_sampling_plan.py`
Связь СОЗ и металлов	`metals_link/`	`pop_metals_link.py`
Демо-стенд	`webapp/pop.py`, `pop_engine.py`, шаблоны `pop_map.html`, `pop_model.html`; инструкция `webapp/POP_STAND.md`	—
Сводная таблица	`chemicals_tj_pop_summary.xlsx`	—

Все компоненты — открытое ПО (Python, scikit-learn, GeoPandas, Flask, Leaflet) и работают без доступа в интернет.